

目录


语义分割网络剖析	1
1.UNet 系列	1
1.1 UNet	1
1.2 UNet++	3
1.3 UNet 3+	4
2.FCN	4
FPN	5
FCN, FPN, UNet 对比总结:	5
3.SegNet	6
4.PSPNet	6
5.DeepLab 系列	6
5.1 DeepLab v1	6
5.2 DeepLab v2	6
5.3 DeepLab v3	7
5.4 DeepLab v3+	7

语义分割网络剖析

语义分割是图像分割中的基本任务，是指对于图像将每个像素都标注上对应的类别，不区分个体。

1.UNet 系列

1.1 UNet



编码器-解码器架构，四次下采样（maxpooling），四次上采样（转置卷积），形成了 U 型结构。

网络首先对输入图片进行了 4 组卷积和下采样操作来获取图像的高阶特征，之后同样通过 4 组反卷积将图像放大回接近输入图像的大小。

Unet 最核心的一个思想：特征图的拼接

Unet 一个重要的创新是在相同深度的 block 之间加入了跳转连接。

UNet 网络有几个主要的特点：

① 网络可以从中间分为左右两部分，左边是收缩路径，利用降采样和卷积模块提取不同尺度的特征；右边是扩展路径，利用上采样和卷积模块恢复尺度并融合先前特征，逐渐恢复图像；

② 卷积模块由两层连续的卷积层组成，它可以实现更大尺寸和更高深度的特征提取；降采样实现图像尺度的缩小；上采样(或反卷积层)实现图像尺度的变大；

③ 图中灰色的箭头线表示跳连，作用是在同一尺度下，将收缩路径上的特征合并到扩展路径上的特征，这样可以在扩展路径上提供更好的约束，网络也更容易输出我们期望的结果。

从 UNet 结构图可以知道，收敛路径主要的过程为

(1) 首先定义重复使用的卷积模块(函数)

重复两次“卷积层 → 标准化层 → 激活函数”，即创建了两个串联的卷积层，这是一种常用的特征提取器，最后输出 X。

(2) 收敛路径

输入图片 → ①(卷积模块 → 下采样 → dropout 层) → ②(卷积模块 → 下采样 → dropout 层) → ③(卷积模块 → 下采样 → dropout 层) → ④(卷积模块 → 下采样 → dropout 层)

`img = Input(shape=self.shape) # self.shape 是图片维度大小`

`c1 = conv2d_block(img, n_filters=n_filters * 1,`

`kernel_size=3, batchnorm=batchnorm, padding=padding)`

`p1 = MaxPooling2D((2, 2))(c1)`

`p1 = Dropout(dropout * 0.5)(p1)`

.....

(3) 扩展路径

输入上一层的输出 → ⑥(上采样 → 特征合并 → dropout 层 → 卷积模块) → ⑦(上采样 → 特征合并 → dropout 层 → 卷积模块) → ⑧(上采样 → 特征合并 → dropout 层 → 卷积模块) → ⑨(上采样 → 特征合并 → dropout 层 → 卷积模块)。

`u6 = Conv2DTranspose(n_filters * 8, (3, 3), strides=(2, 2), padding='same')(c5)`

`u6 = concatenate([u6, c4])`

```

u6 = Dropout(dropout)(u6)
c6 = conv2d_block(u6, n_filters=n_filters * 8,
kernel_size=3, batchnorm=batchnorm, padding=padding)
.....

```

(4) 输出层

根据输出图片的数据格式，可以定义我们的输出层：

```
output = Conv2D(1, (1, 1), activation='sigmoid')(c9)
```

```
return Model(img, output)
```


简要总结：

- 首先进行 Conv+Pooling 下采样；
- 然后反卷积进行上采样，crop 之前的低层 feature map，进行融合；
- 再次上采样。
- 重复这个过程，直到获得输出 388x388x2 的 feature map，
- 最后经过 softmax 获得 output segment map。总体来说与 FCN 思路非常类似。

FCN、Unet、Unet++： 医学图像分割网络一览

1.2 UNet++

UNet++是在 UNet 的基础上添加嵌套和密集跳过连接的



CNN.

借鉴了 *DenseNet* 的密集连接，对 Unet 改进的点主要是 **skip connection**，下图所示，其中黑色部分代表的就是原始 Unet 结构，绿色代表添加的卷积层，蓝色代表改进的 skip connection，每一个水平层就是非常标准的 DenseNet 的结构。

引入了深度监督的思路。网络的 loss 函数是由不同层得到的分割图

的 loss 的平均，每层的 loss 函数为 Dice loss 和 Binary cross-entropy loss 之和，引入 DSN(deep supervision net)后，通过 model pruning（**模型剪枝**）能够实现模型的两种模式：高精度模式和高速模式。

UNet++性能的提升和参数量无直接关系，和网络结构有关。


为什么 UNet++可以被剪枝？

测试时，剪掉部分对剩余结构不做影响；训练时，剪掉的分支对剩余部分有影响。

如何剪枝？根据**子网络**在验证集的结果来决定剪多少。

剪枝好处在哪里？模型的内存可以节省 18 倍（移动端使用）。

1.3 UNet 3+



(c) UNet 3+

(Full-scale skip connections)

使用全尺度的**跳跃连接**把不同尺度的特征图相融合，并且通过**深度监督**从多尺度聚合的特征图中学习特征表达，还提出了一种**混合损失函数**，将**分类任务**和**分割任务**相结合可以增强器官边界和减少非器官图像的过度分割，从而获得更准确的分割结果。

2.FCN

思路：通过将全连接层变成上采样层来恢复特征图的尺寸，进行端到端训练。采用 VGG 作为效果最好，但是推理最慢；

核心的思想是**特征图的融合**；

backbone 是分类网络，下采样都是 maxpooling，上采样使用的是双线性插值初始化的转置卷积。

做语义分割，核心思想：

- **不含全连接层(fc)的全卷积(fully conv)网络**。可适应任意尺寸输入。

- 增大数据尺寸的反卷积(deconv)层。能够输出精细的结果。
- 结合不同深度层结果的跳级(skip)结构。同时确保鲁棒性和精确性。

FPN




Figure 3. A building block illustrating the lateral connection and the top-down pathway, merged by addition.

单一维度的图片作为输入，然后它会选取所有层的特征来处理然后再联合起来做为最终的特征输出组合。

1. 普通 CNN 特征自底至上逐层浓缩表达特征的一个过程；
2. 自上至下的：在将上层 feature map 等比例放大后再与本层的 feature maps 做逐个元素地 (element wise) 相加。
3. CNN 层特征与每一级别输出之间的表达关联。用 1x1 的 Conv 即可生成较好的输出特征，它可有效地降低中间层次的 channels 数目。

FCN, FPN, UNet 对比总结：

三者都是对称的下采样再上采样的全卷积网络。

在上采样方式上：

FCN 和 U-Net 都是使用以双线性插值为初始值的反卷积；

FPN 最近邻上采样。

在特征融合：


FCN 将不同尺度的特征简单相加； (tf.add)

U-Net 将浅层特征截取后和高层特征拼接； (tf.concat)

FPN 是用 1*1 卷积处理浅层特征图再和高级特征相加。


3.SegNet

使用编码器-解码器结构，backbone 是 2 个 VGG16，去掉全连接层；
核心的想法是提出了 maxpool 索引来解码的方法，节省了内存；



4.PSPNet


核心 idea 是提出了金字塔池化模块，模型带有空洞卷积；
金字塔池化 (Pyramid pooling) 融合了四个比例的特征，结合多尺寸信息：SPP
其 backbone 为修改 Resnet-101 为 ResNet-103，而且有辅助 loss，上采样是双线性插值。



5.DeepLab 系列

5.1 DeepLab v1


核心思想是使用空洞卷积扩大感受野，条件随机场 (CRF) 细化边界
backbone 是 VGG16，下采样 8 倍



5.2 DeepLab v2


和 v1 比多了 ASPP (空洞空间卷积池化金字塔)
流程上是 DCNN + Atrous convlution + CRF

backbone 是 VGG16 和 ResNet-101，下采样 8 倍
ASPP 是多尺度下融合特征，CRF 是进行边界的精确化



5.3 DeepLab v3

和 v2 的区别在于 ASPP 多了 image-level feature，没有使用 CRF
提出了 mutil-grid，改进了级联网络的性能
流程上是端到端训练，backbone 是 ResNet-101
下采样有 8 倍和 16 倍两种，8 倍性能更好
计算损失时，将输出的上采样



5.4 DeepLab v3+

和 v3 的区别是多了一个解码器模块，backbone 用了 Aligned Xception（其中有深度可分解卷积）
PASCAL VOC 2012 达到了 87.8% 的 mIOU，在 JFT 预训练的 DeepLab v3+ 在 PASCAL VOC 2012 上至今领先，

达到了 80%，但是 JFT-300M 是谷歌的内部数据集，不开源

